

Büyük Veri Analizi Final Projesi — Kısa Sonuç Özeti

Veri Seti: Heart Disease Risk Factors and Patient Health Survey | **Kurum:** Mersin Üniversitesi - Yönetim Bilişim Sistemleri | *Öykü Sınmaz*

Bu proje, kardiyovasküler hastalık tahminlemesi için veri seti üzerinde uygulanan uçtan uca Büyük Veri Analizi ve Makine Öğrenmesi (ML) süreçlerini kapsar. Temel bulgular aşağıda özetlenmiştir:

1. Veri Seti Özeti ve Yapısal Durum

- Hacim ve Bütünlük:** 328 birey, 21 değişkenden oluşur. Eksik değer (Null) kayıt yoktur.
- Hedef Değişken (Heart Patient):** 108 hasta (%33.0), 219 sağlıklı (%67.0) birey ile sınıflar arası belirgin bir dengesizlik (Class Imbalance) mevcuttur.
- Değişkenler:** 3 sürekli sayısal (Boy, Kilo, BMI) ve 18 kategorik (demografik, klinik, yaşam tarzı) değişken içerir.

2. Temel Bulgular ve Risk Faktörleri

- Demografi ve Genetik:** 50 yaş üstü bireylerde ve ailede kalp hastalığı öyküsü bulunanlarda hastalık riski belirgin şekilde tepe noktasına ulaşmaktadır.
- Klinik Faktörler:** Hipertansiyon ve Diyabet tanısı, sağlıklı popülasyona kıyasla kalp krizi riskini domine eden en güçlü komorbiditelerdir (eşlik eden hastalık).
- Obezite Baskısı (BMI):** Hastaların medyan BMI değeri, sağlıklı gruba göre istatistiksel olarak daha yüksekte (obezite sınırında) konumlanmıştır.
- Yaşam Tarzı:** Düzenli sigara kullanımı ve yüksek stres hastalık oranını tırmandırırken; haftada 5 gün ve üzeri fiziksel aktivite koruyucu etki göstererek riski minimize etmiştir.

3. Makine Öğrenmesi Performans Karşılaştırması

Sınıflandırma Modeli	Accuracy (Doğruluk)	Precision (Kesinlik)	Recall (Duyarlılık)	F1-Score	ROC-AUC
Lojistik Regresyon	0.758	0.875	0.318	0.467	0.782
Karar Ağacı	0.727	0.611	0.500	0.550	0.715
Random Forest	0.727	0.700	0.318	0.438	0.822

4. Analitik Model Yorumu

- En Başarılı Model:** Sınıfları ayırma gücünü ölçen ROC-AUC metriğinde en yüksek skora (**0.822**) topluluk öğrenmesi tabanlı Random Forest ulaşmıştır.
- Metrik Yanılgısı:** %67'lik sağlıklı yığılması nedeniyle *Accuracy* tek başına yanıltıcıdır. Klinik sistemlerde asıl kritik olan "hastayı kaçırma" riskini ölçen *Recall* değerleri (%31-50), veri dengesizliğinden dolayı düşük kalmıştır.
- Karar Mekanizması:** Random Forest modeli (Feature Importance); hastaların genetik geçmişinden ziyade anlık fiziksel ölçümlerine (**BMI, Kilo, Boy ve Tansiyon**) odaklanarak en yüksek bilgi kazancını sağlamıştır.

5. Sınırlılıklar ve Gelecek Vizyonu

- Veri ve Klinik Kısıtlar:** 327 kişilik küçük örneklem algoritmik genellemeyi zorlaştırmaktadır. Hedef değişken ve yaşam tarzı girdileri *öz-bildirimli (self-reported)* olduğu için nesnelliği sınırlıdır (kesin EKG veya laboratuvar değerleri eksiktir).
- Geliştirme Vizyonu:** Sistemin gerçek bir hastane "Karar Destek Sistemi (KDS)" olabilmesi için daha geniş/dengeli veri setlerine ihtiyaç vardır. Sentetik Veri Çoğaltma (**SMOTE**) ve hiperparametre optimizasyonu kullanılarak Recall performansı klinik standartlara (%85+) çekilmelidir.