

Büyük Veri Analizi

Final Projesi

Heart Disease Risk Factors and Patient Health Survey Dataset



Öğrenci Adı Soyadı: Öykü Sınmaz

Üniversite: Mersin Üniversitesi

Bölüm: Yönetim Bilişim Sistemleri

Ders: Büyük Veri Analizi Final Projesi

Tarih: Haziran 2026

1. Giriş: Problem Tanımı ve Analitik Çözüm Yaklaşımı

Problem Tanımı

Kardiyovasküler hastalıklar, dünya çapında en kritik halk sağlığı sorunlarından biridir. Geleneksel sağlık yönetimi genellikle "reaktif" çalışır; yani hastaya müdahale, ancak hastalık klinik bir boyuta ulaştığında gerçekleşir. Bu durumun temel sebebi, kalp hastalıklarının sadece laboratuvar testleriyle değil; stres, kötü beslenme, uykusuzluk ve hareketsizlik gibi çok sayıda "gizli" yaşam tarzı faktörünün yıllar süren karmaşık etkileşimiyle ortaya çıkmasıdır. Bu kadar fazla ve dağınık değişkenin birbiriyle olan doğrusal olmayan (non-linear) ilişkilerini insan gözüyle veya geleneksel yöntemlerle eşzamanlı olarak tespit etmek oldukça zordur.

Çözüm Yaklaşımı Bu proje, reaktif sağlık yaklaşımını veriye dayalı ve "proaktif" (önleyici) bir Karar Destek Sistemine (KDS) dönüştürmeyi hedeflemektedir. Heart_Dataset_Cleaned.csv veri seti üzerinde uygulanacak veri madenciliği ve keşifsel veri analizi (EDA) teknikleriyle, bireylerin demografik bilgileri, gündelik alışkanlıkları ve klinik bulguları bütüncül bir şekilde incelenecektir. Nihai olarak, elde edilen istatistiksel içgörüler makine öğrenmesi algoritmalarıyla desteklenerek, henüz klinik tabloya yansımamış risk faktörlerinin önceden tespit edilmesi sağlanacaktır.

Bölüm A — Veri Setini Tanıma

Analiz sürecinin ilk aşamasında, veri seti Python ortamında (Pandas kütüphanesi kullanılarak) içeri aktarılmış ve verinin yapısal iskeletini anlamak adına temel keşifsel analiz adımları uygulanmıştır.

1. Veri Setinde Kaç Satır ve Kaç Sütun Vardır?

Python üzerinde yapılan .shape analizi sonucunda, veri setinin 328 satır (gözlem) ve 21 sütundan (değişken) oluştuğu tespit edilmiştir.

- Proje yönergesinde belirtilen yaklaşık 328 bireylik kapasiteyle birebir örtüşen bu yapı, her bir satırın araştırmaya katılan tekil bir hastayı temsil ettiğini göstermektedir.
- 21 sütun ise bu hastalara ait yaş, cinsiyet, boy, kan basıncı gibi ayırt edici sağlık ve demografik özellikleri (features) ifade etmektedir.

2 ve 3. Değişken İsimleri Nelerdir ve Hangi Değişkenler Kategorik/Sayısaldır?

Veri setinde yer alan 21 değişken, proje yönergesinde belirtildiği üzere üç ana kategoride toplanmıştır. Değişkenlerin isimleri ve modelleme aşamasındaki istatistiksel yapıları (Kategorik/Sayısal) aşağıdaki tabloda detaylıca sınıflandırılmıştır:

Değişken (Sütun) İsmi	Veri Tipi	Veri Sınıfı ve Kategorisi	Değişkenin Kapsamı
Age	Kategorik	Demografik Değişken	Yaş grupları (<35, 35-50, >50).
Gender	Kategorik	Demografik Değişken	Bireyin cinsiyeti (Male/Female).
Marital status	Kategorik	Demografik Değişken	Medeni durum.
Living situation	Kategorik	Demografik Değişken	Kiminle yaşandığı.
Occupation / Daily Activities	Kategorik	Yaşam Tarzı Değişkeni	Mesleki hareketlilik.

Değişken (Sütun) İsmi	Veri Tipi	Veri Sınıfı ve Kategorisi	Değişkenin Kapsamı
Food habits	Kategorik	Yaşam Tarzı Değişkeni	Beslenme kalitesi.
Physical activity	Kategorik	Yaşam Tarzı Değişkeni	Fiziksel egzersiz sıklığı.
Sleep at night	Kategorik	Yaşam Tarzı Değişkeni	Uyku düzeni ve kalitesi.
Depression	Kategorik	Yaşam Tarzı Değişkeni	Depresyon belirtileri.
Smoke or Tobacco	Kategorik	Yaşam Tarzı Değişkeni	Tütün kullanım sıklığı.
Alcohol	Kategorik	Yaşam Tarzı Değişkeni	Alkol tüketim alışkanlığı.
Feel stressed	Kategorik	Yaşam Tarzı Değişkeni	Hissedilen stres seviyesi.
Family Heart problems History	Kategorik	Klinik Değişken	Ailede kalp hastalığı öyküsü.
Family Diabetes History	Kategorik	Klinik Değişken	Ailede diyabet öyküsü.
Blood Pressure	Kategorik	Klinik Değişken	Kan basıncı düzeyi.
Diabetes	Kategorik	Klinik Değişken	Bireysel diyabet durumu.
Medicines	Kategorik	Klinik Değişken	İlaç kullanım durumu.
Heart patient	Kategorik	Hedef Değişken	Kalp hastalığı teşhisi.
Height (cm)	Sayısal	Sürekli Klinik Ölçüm	Hastanın boy uzunluğu.
Weight	Sayısal	Sürekli Klinik Ölçüm	Hastanın vücut ağırlığı.
BMI	Sayısal	Sürekli Klinik Ölçüm	Hastanın Vücut Kitle İndeksi değeri.

Yorum: Görüldüğü üzere veri setinde sadece 3 adet sürekli sayısal değişken (Boy, Kilo, BMI) bulunurken, geriye kalan 18 değişken kategoriktir. Bu durum, modelleme (Bölüm E) aşamasında metinsel kategorik verilerin sayısallaştırılması için özel veri kodlama (Encoding) işlemlerinin yapılmasını zorunlu kılmaktadır.

4. Hedef Değişken Hangisidir?

Gerçekleştirilecek tüm istatistiksel analizlerin ve kurulacak sınıflandırma modellerinin nihai amacı kişinin kalp hastası olup olmadığını tahmin etmek olduğu için, projenin hedef değişkeni (Target Variable) Heart patient sütunudur. Bu değişken sadece "Yes" (Evet) ve "No" (Hayır) değerlerini alan ikili (binary) bir kategorik veri tipidir.

5. Veri Setinde Eksik Değer Var Mıdır?

Makine öğrenmesi modellerinin sağlığı açısından en kritik adımlardan biri olan eksik veri (Missing Value) kontrolü yapılmıştır. Python'da çalıştırılan analiz neticesinde veri setindeki hiçbir hücrede eksik (NaN veya Null) değere rastlanmamıştır. Veri seti adından da anlaşılacağı üzere "Cleaned" (Temizlenmiş) olarak sunulduğu için yapısal bir bütünlüğe sahiptir.

6. Veri Setinde Tekrar Eden Kayıt Var Mıdır?

Modelin belirli profilleri ezberlemesini (overfitting) önlemek amacıyla aynı satırın birden fazla kez girilip girilmediği kontrol edilmiştir. Yapılan veri taramasında veri setinde satır bazında mükerrer (duplicate) bir kayda rastlanmamıştır. Her bir katılımcı girdisi veri seti içerisinde eşsiz (unique) özellik kombinasyonları taşımaktadır.

Bölüm B — Tanımlayıcı İstatistikler

Keşifsel Veri Analizi (EDA) sürecinin temel taşı olan tanımlayıcı istatistikler, verinin matematiksel karakteristiğini ve dağılımını anlamamızı sağlar. Analize konu olan 327 gözlem üzerinden elde edilen nicel (sayısal) ve nitel (kategorik) metrikler, proje yönergesindeki sorulara istinaden aşağıda detaylıca raporlanmıştır.

1. Sayısal Değişkenlerin İstatistiksel Özeti

Veri setindeki klinik ölçümleri ifade eden Height (cm), Weight ve BMI sayısal değişkenlerine ait temel eğilim ve yayılım ölçütleri hesaplanarak aşağıdaki tabloda sunulmuştur:

Sayısal Değişken	Gözlem (N)	Ortalama (Mean)	Medyan (Median)	Standart Sapma	Minimum Değer	Maksimum Değer	Veri Dağılımı ve Analitik Yorum
Height (cm)	327	163.07	162.60	6.79	137.20	182.90	Ortalama (163.07) ve medyan (162.60) değerlerinin birbirine çok yakın olması, boy dağılımının çarpıklıktan uzak, mükemmel bir simetrik (normal) dağılım sergilediğini kanıtlar.
Weight (kg)	327	67.18	68.00	11.93	42.00	103.00	Minimum (42 kg) ve maksimum (103 kg) ağırlık arasındaki geniş fark, standart sapmayı (11.93) artırarak veri setindeki vücut tiplerinin yüksek varyansını (heterojenliğini) göstermektedir.

Sayısal Değişken	Gözlem (N)	Ortalama (Mean)	Medyan (Median)	Standart Sapma	Minimum Değer	Maksimum Değer	Veri Dağılımı ve Analitik Yorum
BMI	327	25.24	24.95	4.22	16.51	42.46	Ortalama Vücut Kitle İndeksinin 25.24 olması, örneklemin genel olarak tıp literatüründe "Fazla Kilolu" (Overweight) sınırına geçtiğini işaret etmektedir. Maksimum değer olan 42.46, morbid obezite bulgusudur.

Yorum: Bireylerin BMI (Vücut Kitle İndeksi) ortalaması 25.24 ile "Fazla Kilolu" sınırına dayanmaktadır. Maksimum BMI değeri olan 42.46 (morbid obezite) gibi aşırı uç değerler, algoritmaların (özellikle Logistic Regression) hata payını artırabileceğinden, modelleme aşamasında bu sayısal değişkenlerin standartlaştırılması (Scaling) gerekliliğini ortaya koymaktadır.

2. Kategorik Değişkenler İçin Frekans ve Yüzde Tabloları

Modelin öğrenme katsayılarını doğrudan etkileyen kritik demografik ve klinik kategorik değişkenlere ait dağılımlar, frekans (adet) ve yüzdelik oranlar üzerinden analiz edilmiştir:

A. Yaş Grupları Dağılımı (Age)

Yaş Grubu Sınıfı	Frekans (Kişi Sayısı)	Veri Seti İçindeki Oranı (%)
> 50 (50 Yaş Üstü)	131	%40.06
35–50 Yaş Arası	109	%33.33
< 35 (35 Yaş Altı)	87	%26.61

Yorum: Veri setinin %40.06'sını (en büyük dilimini) 50 yaş üstü bireyler oluşturmaktadır. Bu durum, kalp hastalıklarının ilerleyen yaşlarda daha sık görülmesi gerçeğiyle örtüşmekte olup, "Age" değişkeninin model kararlarında (Feature Importance) yüksek bir ağırlığa sahip olacağının güçlü bir sinyalidir.

B. Cinsiyet Dağılımı (Gender)

Cinsiyet	Frekans (Kişi Sayısı)	Veri Seti İçindeki Oranı (%)
Erkek (Male)	196	%59.94
Kadın (Female)	131	%40.06

Yorum: Örneklemenin %59.94'ü erkek, %40.06'sı kadındır. Cinsiyetler arası %20'lik bu fark, Karar Ağacı tabanlı algoritmalar için sorun yaratmayacak, kabul edilebilir bir istatistiksel sapmadır. Her iki cinsiyet sınıfı da modelin cinsiyet faktörünü öğrenebileceği kadar yeterli veriye sahiptir.

C. Kan Basıncı Seviyeleri (Blood Pressure)

Kan Basıncı Kategorisi	Frekans (Kişi Sayısı)	Veri Seti İçindeki Oranı (%)
Normal	122	%37.31
Pre-hypertension	102	%31.19
Hypertension	86	%26.30
Hypotension	17	%5.20

Yorum: Popülasyonun sadece %37.31'inin tansiyonu "Normal" seviyededir. Katılımcıların yarısından fazlasının (%57.49) Pre-hipertansiyon veya Hipertansiyon sınıfında yer alması , veri setindeki kitlenin kardiyovasküler risk açısından son derece dezavantajlı bir profil çizdiğini istatistiksel olarak kanıtlamaktadır.

3. Hedef Değişken (Heart Patient) Sınıf Dağılımı

Bütün makine öğrenmesi tahminlerinin dayandığı Heart patient (Kalp hastası mı?) hedef değişkeninin dağılımı, projenin analitik dengesini belirleyen en önemli unsurdur:

Teşhis Durumu	Frekans (Kişi Sayısı)	Veri Seti İçindeki Oranı (%)	Sınıf Dengesizliği Yorumu
No (Sağlıklı Birey)	219	%66.97	Çoğunluk sınıfıdır. Algoritmanın "herkes sağlıklı" diyerek kolaya kaçmasını engellemek gerekir.
Yes (Kalp Hastası)	108	%33.03	Azınlık sınıfıdır. Modelin asıl odaklanması ve tespit etmesi gereken kitle bu gruptur.

Yorum: Modelin tahmin edeceği "Yes" (Kalp Hastası) sınıfı, %33.03'lük oranıyla azınlık durumundadır. Bu "Sınıf Dengesizliği" (Class Imbalance), modelin salt "Accuracy" (Doğruluk) metriğine göre değil, azınlıktaki hastaları doğru bulabilme yeteneğini ölçen "Recall" (Duyarlılık) metriğine göre değerlendirilmesini zorunlu kılmaktadır.

4. Proje Yönergesi Kapsamındaki Soruların İstatistiksel Yanıtları

Veri setinde kaç kişi kalp hastasıdır?

- Yapılan frekans analizi sonucunda, veri setinde tam olarak **108 bireyin** kalp hastası olduğu ("Yes" sınıfında yer aldığı) tespit edilmiştir.

Kalp hastası olanların oranı nedir?

- 327 kişilik toplam popülasyon içerisinde kalp hastası olan bireylerin oranı **%33.03**'tür. Kalan %66.97'lik kesim sağlıklı bireyleri temsil etmektedir.

Kadın ve erkek katılımcı sayıları nasıldır?

- Araştırmaya katılan bireylerin **196'sı Erkek (Male)**, **131'i ise Kadın (Female)** katılımcılardan oluşmaktadır. Erkek katılımcılar %59.94'lük bir ağırlığa sahiptir.

En yaygın yaş grubu hangisidir?


- Veri setindeki en yaygın (dominant) yaş grubu **"> 50" (50 yaş üstü)** kategorisidir. 131 kişi ile toplam örneklemin %40.06'sını oluşturmaktadır. Bu sonuç, kardiyovasküler riskin ilerleyen yaşlarda artması şeklindeki tıbbi beklentiyle mantıksal bir uyum içindedir.

En yaygın kan basıncı kategorisi hangisidir?

- Örneklem içerisinde en sık rastlanan kan basıncı kategorisi **"Normal"** (122 kişi - %37.31) seviyesidir. Ancak hemen ardından gelen **"Pre-hypertension"** (102 kişi) ve **"Hypertension"** (86 kişi) kategorileri birlikte değerlendirildiğinde, popülasyonun yarıdan fazlasında tansiyon yüksekliği problemi olduğu görülmektedir.

Bölüm C — Veri Görselleştirme


1. Kalp Hastası Dağılımı:



Amacı: Makine öğrenmesi modellerinin eğiteceği "hedef (target)" verinin genel popülasyon içindeki denge durumunu saptamak.

- İstatistiksel ve Analitik Yorum:** Bar grafiği incelendiğinde, veri setinde yer alan bireylerin büyük bir çoğunluğunun (219 kişi) sağlıklı olduğu, kalp hastası olan bireylerin (108 kişi) ise azınlıkta kaldığı net bir şekilde görülmektedir. Yaklaşık 2/3 oranındaki bu fark, veri madenciliği terminolojisinde Sınıf Dengesizliği (Class Imbalance) olarak adlandırılır. Bu görsel bize çok kritik bir uyarı vermektedir: Kurulacak makine öğrenmesi modelleri sadece "Doğruluk (Accuracy)" metriği üzerinden değerlendirilmemelidir. Model herkesi "sağlıklı" tahmin etse dahi %67 doğruluk oranına ulaşacaktır. Bu nedenle model performansında gerçek hastaları bulma gücünü yansıtan "Recall (Duyarlılık)" metriğine odaklanılması gerektiği grafiksel olarak kanıtlanmıştır.


2.Yaş Grubuna Göre Kalp Hastalığı Dağılımı:



Amacı: Yaş faktörünün (Age), kardiyovasküler hastalıkların gelişimindeki doğrusal veya logaritmik etkisini gruplar bazında incelemek.

- İstatistiksel ve Analitik Yorum:** Grafikteki üç yaş grubu (<35, 35-50, >50) karşılaştırıldığında, hastalığın (kırmızı sütun) yaş ilerledikçe dramatik bir artış sergilediği saptanmıştır. Özellikle 35 yaş altı grupta kalp hastalığı vakaları yok denecek kadar azken, 50 yaş üstü (">50") gruba geçildiğinde kırmızı sütunun mavi sütuna neredeyse eşitlendiği (risk oranının %50 bandına yaklaştığı) görülmektedir. Bu bulgu tıp bilimiyle mükemmel bir uyum göstermektedir ve "**Yaş**" değişkeninin ağaç tabanlı algoritmalar (Decision Tree, Random Forest) için en güçlü ayırt edici öznelik (Feature Importance) olarak ilk düğümlerde (root node) kullanılacağını işaret etmektedir.


3.Cinsiyete Göre Kalp Hastalığı Dağılımı:



Amacı: Biyolojik cinsiyetin hastalık üzerindeki etkisini ve dağılımını gözlemlemek.

- İstatistiksel ve Analitik Yorum:** Erkek (Male) ve Kadın (Female) gruplarının kendi içlerindeki dağılımı incelendiğinde, veri setindeki toplam erkek sayısının kadınlardan daha fazla olduğu (mavi sütunların yüksekliği) görülmektedir. Ancak önemli olan mutlak sayılar değil, oransal dağılımdır. Her iki cinsiyette de "Yes" (kırmızı sütun) ve "No" (mavi sütun) oranlarının birbirine oldukça paralel bir seyir izlediği tespit edilmiştir. Bu durum, "Cinsiyet" değişkeninin tek başına hastalık teşhisinde çok radikal bir belirleyici olmadığını, ancak yaş veya kan basıncı gibi diğer parametrelerle birleştğinde modele anlamlı bir katkı sunabileceğini göstermektedir.


4.BMI (Vücut Kitle İndeksi) Dağılımı ve Hastalık İlişkisi



Amacı: Sürekli (sayısal) bir değişken olan Vücut Kitle İndeksinin dağılımını, medyan farklarını ve aşırı obeziteyi simgeleyen aykırı değerleri (outliers) kutu grafiği üzerinden analiz etmek.

- İstatistiksel ve Analitik Yorum:** İki sınıfın kutu grafikleri (Boxplot) karşılaştırıldığında, kalp hastası olan grubun ("Yes" - Kırmızı) ortanca (medyan) değerinin, sağlıklı gruba kıyasla bariz şekilde daha yukarıda (yaklaşık 27-28 bandında) konumlandığı görülmektedir. Sağlıklı bireylerin verileri daha dar bir aralıkta ve normal kiloya yakın seyrederken, hastaların "Çeyrekler Açıklığı" (IQR - kutunun yüksekliği) obezite sınırlarına doğru genişlemektedir. Grafiğin üst kısımlarındaki noktalar (35 ve 40+ BMI), morbid obezitenin kalp krizi ile olan doğrudan korelasyonunu yansıtan uç değerleri (outliers) temsil etmektedir.


5. Kan Basıncı (Blood Pressure) Seviyelerine Göre Hastalık



Amacı: Sistolik ve diyastolik basınç dengesizliğinin (hipertansiyon) hastalığı tetikleme şiddetini kategorik olarak doğrulamak.

- İstatistiksel ve Analitik Yorum:** Veri setindeki en çarpıcı içgörülerden biri bu grafikte saklıdır. "Normal" kan basıncına sahip grupta sağlıklı bireyler (mavi) devasa bir üstünlüğe sahipken, ekseninde "Pre-hypertension" ve özellikle "Hypertension" (Hipertansiyon) kategorilerine doğru ilerledikçe kırmızı sütunun hızla büyüyerek mavi sütunla rekabet eder hale geldiği gözlemlenmiştir. Yüksek tansiyonun kalp kası ve damarlar üzerindeki yıkıcı etkisi görsel verilerle kanıtlanmıştır. Makine öğrenmesi modeli kan basıncını analiz ederken, Hipertansiyon sınıfını bir numaralı "kırmızı bayrak" olarak etiketleyecektir.


6.Fiziksel Aktivite (Physical Activity) ve Hastalık İlişkisi



Amacı: Hareketsiz (sedanter) yaşam tarzının veya düzenli spor yapmanın kardiyovasküler sistem üzerindeki etkilerini davranışsal bir veri boyutuyla ölçmek.

- İstatistiksel ve Analitik Yorum:** Grafikte, egzersiz sıklığının artışıyla hastalık riskinin keskin bir şekilde düştüğü negatif yönlü güçlü bir korelasyon izlenmektedir. "Rarely / Never" (Nadiren / Hiç) egzersiz yapan grupta kalp hastası olma oranı tehlikeli boyutlara ulaşırken, "5 or more days" (Haftada 5 gün ve üzeri) aktif olan grupta hastalık riski neredeyse sıfırlanmıştır. Bu görsel, analizimizin sadece genetik değil, "değiştirilebilir yaşam tarzı alışkanlıklarını" da başarıyla modellediğinin en net göstergesidir.

7.Sigara/ Tütün Kullanımı ve Kalp Hastalığı İlişkisi




Amacı: Modelin genel tahmin başarısının ötesine geçerek; dengesiz veri setindeki "Sağlıklı" (Hayır) ve "Hasta" (Evet) sınıfları üzerindeki ayrıştırma gücünü Kesinlik (Precision), Duyarlılık (Recall) ve F1-Skoru gibi alt metriklerle mikroskobik düzeyde ölçmek.

Support (Gözlem Sayısı) ve Veri Dengesizliği: Tablodaki support sütunu, algoritmanın test edildiği veride 44 "Hayır" (Sağlıklı) ve 22 "Evet" (Hasta) vakası olduğunu doğrulamaktadır. Bu durum, veri görselleştirme (EDA) aşamasında tespit ettiğimiz sınıf dengesizliğinin matematiksel ispatıdır.

- Accuracy (Doğruluk) Yanılgısı:** Raporun altında yer alan accuracy (doğruluk) skoru 0.85 (%85) olarak ölçülmüştür. Standart bir ödevde bu oran yüksek bir başarı gibi sunulsa da, tıbbi bir analizde bu metrik "tuzak" bir metriktir ve tek başına yeterli değildir.
- Çoğunluk Sınıfı ("Hayır") Performansı:** Model, sağlıklı bireyleri tespit etmede son derece rahattır (recall: 0.91, f1-score: 0.89). Algoritma sağlıklı olanların %91'ini doğru bilmiştir çünkü verinin çoğu zaten sağlıklı profillerden oluşmaktadır.
- Asıl Hedef Sınıf ("Evet" - Hasta) Analizi:** Projenin odak noktası olan "Evet" satırına bakıldığında, precision (Kesinlik) oranının 0.80, recall (Duyarlılık) oranının ise 0.73 olduğu görülmektedir.
- Gerçek Hayat Kısıtı (Business & Clinical Value):** Recall değerinin 0.73 olması, sistemin klinik bir zafiyeti olduğunu gösterir. Bu orana göre model, gerçekte kalp hastası olan 22 kişinin yaklaşık %27'sine (6 hastaya) hastalık riskini gözden kaçırarak yanlışlıkla "Sağlıklı" (False Negative) teşhisi koymuştur. Tıbbi bilişim sistemlerinde "yanlış alarm" (False Positive) tolere edilebilirken, "hastayı kaçırmak" (False Negative) ölümcül bir hata maliyetidir.


8.BMI ve Vücut Ağırlığı (Weight) Dağılımı — Serpilme Diyagramı (Scatter Plot)



Amacı: İki sürekli sayısal değişken olan Kilo ve Vücut Kitle İndeksi (BMI) arasındaki doğrusal ilişkiyi (linear correlation) test etmek ve kalp hastalarının ("Yes" - Kırmızı noktalar) hangi veri koordinatlarında kümелendiğini (clustering) tespit etmek.


- Analitik Çıkarımı:** Nokta dağılımları (veri bulutu) incelendiğinde, Kilo ve BMI arasında beklendiği üzere kusursuz bir "pozitif yönlü doğrusal ilişki" olduğu görülmektedir (Kilo arttıkça BMI aynı ivmeyle artmaktadır). Asıl çarpıcı olan veri madenciliği bulgusu ise şudur: Kırmızı noktalar (Kalp Hastaları) grafiğin sol alt köşesinde (Düşük Kilo - Düşük BMI) oldukça seyrekler. Ancak grafiğin sağ üst kadranına (High Weight, High BMI - 80kg ve 30 BMI üstü) doğru ilerledikçe kırmızı noktaların yoğunluğu (density) mavi noktaları bastırarak şekilde kümelenmektedir. Kurulacak makine öğrenmesi modeli (özellikle Karar Ağaçları), bu sağ üst kadranı doğrudan bir "Yüksek Risk Segmenti" olarak kodlayacaktır. Bu görsel, sigorta şirketlerinin veya hastanelerin obezite sınırındaki hastalar için neden "erken uyarı / proaktif müdahale" sistemleri kurması gerektiğini matematiksel olarak ispatlamaktadır.

9.Stres Düzeyi ve Kalp Hastalığı İlişkisi:



Yorum: Gündelik stresin fiziksel sağlığa olan psikosomatik yansıması net bir şekilde görülmektedir. Stres seviyesi "Low" (Düşük) olan grupta kalp hastası sayısı minimum düzeyde kalırken, "High" (Yüksek) stres grubunda kırmızı (hasta) sütunun belirgin şekilde arttığı gözlemlenmiştir. Otonom sinir sistemi üzerindeki stres yükünün hastalıkları tetiklediği model parametrelerine başarıyla yansımıştır.

10. İlaç Kullanımı ve Kalp Hastalığı İlişkisi:




Amacı: Bireylerin düzenli tıbbi ilaç kullanma durumlarının (Hiç kullanmamış, Geçmişte kullanmış, Aktif olarak kullanan), mevcut kardiyovasküler risk tablosuyla olan oransal ilişkisini saptamak.

- İstatistiksel ve Klinik Çıkarım:** Dağılım grafiği incelendiğinde, ilaç kullanım geçmişi olmayan "Never taken" (Hiç Kullanmamış) grubunda mavi sütunların (Sağlıklı Bireyler) ezici bir çoğunluğa sahip olduğu görülmektedir. Ancak grafik sağa doğru kayıp "Yes, I am taking" (Evet, aktif kullanıyorum) kategorisine geldiğinde, durum tamamen tersine dönmekte; kırmızı sütunların (Kalp Hastaları) oranı dramatik bir şekilde artarak sağlıklı grubu geride bırakmaktadır.

Tıbbi Komorbidite Yorumu: Bu durum istatistiksel bir tesadüf değil, tıptaki "komorbidite" (eşlik eden hastalıklar) gerçeğinin veriye yansımasıdır. Aktif olarak ilaç kullanan bireyler büyük ihtimalle tansiyon, kolesterol veya diyabet tedavisi görmektedir ve bu kronik rahatsızlıklar doğrudan kalp krizinin öncü tetikleyicileridir.

- Makine Öğrenmesi (KDS) Etkisi:** Kurduğumuz sınıflandırma algoritmaları (özellikle Karar Ağaçları), "Medicines" değişkenini mükemmel bir *vekil (proxy) değişken* olarak algılayacaktır. Model, hastanın sadece aktif ilaç kullanım durumuna bakarak bile yüksek bir "Bilgi Kazancı" (Information Gain) elde edecek ve o kişiyi yüksek riskli "Yes" sınıfına atamak için güçlü bir matematiksel ağırlık (weight) oluşturacaktır. Bu grafik, analitik modellerin insan mantığına ne kadar paralel çalıştığının görsel bir kanıtıdır.

11.Kilo ve BMI İlişkisi :



- **Güçlü Pozitif Korelasyon:** Kilo (kg) ile BMI arasında beklendiği üzere pozitif ve doğrusal bir ilişki var. Bireylerin kilosu arttıkça BMI değerleri de istikrarlı bir şekilde artış gösteriyor.
- **İç İç Geçmiş Dağılım (Sınıflandırma Zorluğu):** Kalp hastası olanlar (kırmızı noktalar) ile olmayanlar (mavi noktalar) veri setinin büyük bir bölümünde birbirleriyle iç içe geçmiş durumda. Bu durum, sadece Kilo ve BMI özelliklerini (feature) kullanarak bir kişinin kalp hastası olup olmadığını kesin olarak ayırmanın (lineer olarak sınıflandırmanın) oldukça zor olduğunu gösteriyor. Başka değişkenlere de ihtiyaç var.
- **Uç Değerler (Outliers) ve Risk:** Grafiğin sağ üst köşesinde, BMI değerinin en yüksek olduğu noktalara ($BMI > 40$) bakıldığında, bu ekstrem değerlerdeki bireylerin kalp hastası ("Evet") olduğu görülüyor. Yüksek BMI seviyeleri, kalp hastalığı riskinin artmasıyla örtüşüyor gibi duruyor.
- **Artan Saçılım (Varyans):** 40-50 kg bandındaki bireylerin BMI değerleri dar bir alanda toplanırken, kilo 80 kg ve üzerine çıktığında BMI değerlerinin dikeydeki dağılımı (varyansı) çok daha geniş bir alana yayılıyor. Yüksek kilolarda boy değişkeninin BMI formülü üzerindeki etkisi daha belirgin bir saçılıma yol açmış.

Bölüm D — Kalp Hastalığı ile Risk Faktörlerinin İncelenmesi

Bu bölümde, veri setindeki bağımsız değişkenlerin (özelliklerin) hedef değişken olan Heart patient (Kalp Hastalığı) ile olan istatistiksel ve mantıksal ilişkileri incelenmiştir. Yapılan analizlerde Bölüm C'de elde edilen görsel çıktılar (Keşifsel Veri Analizi) referans alınmış ve bulgular tıp literatürü ışığında değerlendirilmiştir.

1. Age (Yaş) Faktörünün İncelenmesi

- **İlişki Durumu:** Yaş değişkeni, kalp hastalığı ile en güçlü ve doğrudan ilişkiye sahip olan demografik faktörlerden biridir.
- **Gruplar Arası Fark:** 35 yaş altı bireylerde kalp hastalığı vakaları minimum düzeydeyken, 50 yaş üstü (>50) grupta hastalık oranında dramatik bir sıçrama yaşanmaktadır. İki grup arasındaki fark istatistiksel olarak son derece belirgindir.
- **Grafik Desteği:** Bölüm C'de çizilen "Yaş Grubuna Göre Kalp Hastalığı Dağılımı" bar grafiği, yaş arttıkça kırmızı sütunların (hasta grubun) mavi sütunları (sağlıklı grubu) yakalama eğiliminde olduğunu net bir şekilde desteklemektedir.
- **Sağlık Bilgisi Açısından Mantık:** Tıbbi literatüre göre insan yaşlandıkça damar çeperleri esnekliğini kaybeder (ateroskleroz riski artar) ve kalp kası yorulur. Bu nedenle yaşın hastalık riskini artırması tıp bilimiyle kusursuz bir uyum içindedir.

2. Blood Pressure (Kan Basıncı) Faktörünün İncelenmesi

- **İlişki Durumu:** Kan basıncı değişkeni, kalp hastalığının en önemli klinik tetikleyicisidir ve güçlü bir ilişki barındırır.
- **Gruplar Arası Fark:** Tansiyonu "Normal" olan grupta kalp hastası olma ihtimali çok düşükken; "Hipertansiyon" (Hypertension) kategorisindeki bireylerde kalp hastası olma oranı, sağlıklı kalma oranını neredeyse geride bırakacak kadar yüksektir.
- **Grafik Desteği:** İlgili bar grafiğinde, hipertansiyon sınıfına geçildiğinde kırmızı (hasta) sütunun marjinal bir şekilde yükseldiği görülerek bu fark görsel olarak doğrulanmıştır.
- **Sağlık Bilgisi Açısından Mantık:** Kan basıncının yüksek olması, kalbin kanı pompalarken damar direncine karşı daha fazla efor sarf etmesine neden olur. Bu durum kalp kasında büyüme ve kalp yetmezliğine yol açtığından, elde edilen bulgu bilinen hipertansiyon-kardiyovasküler hastalık ilişkisi ile tam uyumludur.

3. BMI (Vücut Kitle İndeksi) Faktörünün İncelenmesi

- **İlişki Durumu:** Bireyin kilo ve boy orantısını veren BMI değişkeni, hastalıkla pozitif yönlü (birlikte artan) bir ilişkiye sahiptir.
- **Gruplar Arası Fark:** Kalp hastası olmayan bireylerin BMI medyanı (ortanca değeri) daha düşük ve dar bir aralıkta seyrederken; kalp hastası olan bireylerin BMI değerleri 27-30 (Fazla kilolu/Obez) bandında yoğunlaşmıştır.
- **Grafik Desteği:** Çizilen Kutu Grafiği (Boxplot), hastaların kutu hizasının daha yukarıda konumlandığını ve obezite sınırındaki aykırı değerlerin (outliers) bu grupta toplandığını göstererek hipotezi destekler.
- **Sağlık Bilgisi Açısından Mantık:** Yüksek BMI (Obezite), vücuttaki kan hacmini ve kalbin iş yükünü artırır; ayrıca insülin direnci ve kolesterol ile doğrudan bağlantılı olduğu için kalbi yorması tıbben son derece mantıklıdır.

4. Physical Activity (Fiziksel Aktivite) Faktörünün İncelenmesi

- **İlişki Durumu:** Fiziksel aktivite, hastalık üzerinde "koruyucu" etkiye sahip, negatif yönlü bir ilişkisi olan kritik bir yaşam tarzı değişkenidir.
- **Gruplar Arası Fark:** Haftada 5 gün ve üzeri spor yapan grupta kalp hastalığı riski sıfıra yaklaşırken, "Rarely / Never" (Nadiren / Hiç) egzersiz yapan sedanter grupta kalp hastası oranının katlanarak arttığı belirgin bir farkla saptanmıştır.
- **Grafik Desteği:** İlgili çubuk grafiği, hareket sıklığı arttıkça hasta oranının (kırmızı sütun) adeta bir merdiven gibi azaldığını kusursuzca resmetmektedir.
- **Sağlık Bilgisi Açısından Mantık:** Düzenli kardiyo egzersizleri kalp kasını güçlendirir, damar içi kan akışını düzenler ve kötü kolesterolü düşürür. Bu bulgu kardiyoloji bilimiyle %100 örtüşmektedir.

5. Diabetes (Diyabet) Faktörünün İncelenmesi

- **İlişki Durumu:** Diyabet, kalp hastalığının en yıkıcı "eşlik eden (komorbid)" hastalıklarından biridir ve güçlü bir ilişki sergiler.
- **Gruplar Arası Fark:** Kan şekeri "Normal" olan bireylerin çok büyük kısmı sağlıklı kalırken, "Diabetes" (Şeker Hastası) kategorisindeki bireyler arasında kalp krizi geçirme / kalp hastası olma oranı diğer gruplara kıyasla çok daha yüksektir.
- **Grafik Desteği:** Diyabet grafiğindeki hasta bireylerin (kırmızı sütun) yüksekliği, diyabetin varlığıyla birlikte keskin bir artış göstermektedir.

Sağlık Bilgisi Açısından Mantık: Yüksek kan şekeri zamanla kan damarlarını ve kalbi kontrol eden sinirleri tahrip eder. "Diyabetik bir hastanın eninde sonunda kardiyologla işi olur" şeklindeki klinik gerçeklik veri setimizde matematiksel olarak ispatlanmıştır.

6. Family Heart Problems History (Aile Öyküsü) Faktörünün İncelenmesi

- **İlişki Durumu:** Genetik mirasın gücünü yansıtan bu değişken, kalp hastalığı ile yadsınamaz bir ilişkiye sahiptir.
- **Gruplar Arası Fark:** Ailesinde kalp hastası olmayan bireyler genellikle sağlıklı çoğunluğu oluştururken, ailesinde kalp hastalığı bulunan ("Yes") bireylerde hastalığın ortaya çıkma frekansı radikal bir şekilde yükselmektedir.
- **Grafik Desteği:** Görsel analiz, aile öyküsü "Yes" olduğunda risk marjının tehlikeli bir şekilde daraldığını net bir şekilde gözler önüne sermiştir.
- **Sağlık Bilgisi Açısından Mantık:** Genetik faktörler; hücre yapısını, kolesterol metabolizmasını ve damar sağlığını doğrudan kodlar. Bu nedenle genetik yatkınlığın hastalanma riskini artırması tamamen rasyonel bir tıp gerçeğidir.

7. Feel Stressed (Stres Düzeyi) Faktörünün İncelenmesi

- **İlişki Durumu:** Psikolojik bir veri olan stres, kardiyovasküler sistem üzerinde otonom bir etkiye sahiptir ve hastalıkla ilişkilidir.
- **Gruplar Arası Fark:** Stres seviyesi "Low" (Düşük) olan bireylerde hastalık oranı %10'ların altında seyrederken, stres seviyesi "High" (Yüksek) olanlarda bu oran çok daha belirgin bir şekilde artmaktadır.
- **Grafik Desteği:** Stres çubuk grafiği, stres seviyesi tırmandıkça kalp hastalığı teşhisinde kademeli bir artış olduğunu grafiksel olarak doğrulamaktadır.
- **Sağlık Bilgisi Açısından Mantık:** Kronik stres, vücutta sürekli olarak adrenalin ve kortizol hormonlarının salgılanmasına, bu da kalp ritminin hızlanmasına ve damarların daralmasına (vazokonstriksiyon) yol açar. Bulgular psikosomatik sağlık ilkeleriyle tamamen uyumludur.

8. Smoke or Tobacco (Sigara/Tütün Kullanımı) Faktörünün İncelenmesi

- **İlişki Durumu:** Sigara kullanımı, önlenebilir ölüm nedenlerinin başında gelir ve kalp hastalığı ile doğrudan toksik bir ilişkisi vardır.
- **Gruplar Arası Fark:** Hayatı boyunca hiç sigara içmemiş ("Never") bireyler ile düzenli içiciler ("Regularly") karşılaştırıldığında, düzenli içicilerin bulunduğu popülasyonda kalp hastası çıkma oranının çok daha yoğun olduğu tespit edilmiştir.
- **Grafik Desteği:** Görsel veriler, sigara içme frekansı ile kalp hastası (Yes) sütunu arasında doğrusal bir artış olduğunu net bir şekilde göstermiştir.

Sağlık Bilgisi Açısından Mantık: Tütün dumanındaki karbonmonoksit kandaki oksijenin yerini alır, nikotin ise kalp atışını hızlandırarak damarları büzer. Bu iki etkinin birleşmesi doğrudan pıhtı atmasına ve kalp krizine neden olduğu için veriler hayatın gerçeğini yansıtmaktadır.

9. Medicines (İlaç Kullanımı) Faktörünün İncelenmesi

- **İlişki Durumu:** İlaç kullanımı tek başına hastalığın "nedeni" olmasa da, hastalığın çok güçlü bir "göstergesi" (proxy variable) olarak veri setinde ilişkili bulunmuştur.
- **Gruplar Arası Fark:** Düzenli olarak tıbbi ilaç kullanan ("Yes, I am taking") gruptaki bireylerin büyük bir kısmının aynı zamanda kalp hastası ("Yes") etiketine sahip olduğu, ilaç kullanmayanlarda ise sağlığın korunduğu görülmüştür.
- **Grafik Desteği:** İlaç kullanım grafiği incelendiğinde, ilaç kullanımının olduğu sınıfta hastalık riskinin diğer tüm grupları geride bıraktığı grafiksel olarak da desteklenmiştir.
- **Sağlık Bilgisi Açısından Mantık:** Aktif ilaç kullanımı, hastanın muhtemelen tansiyon, diyabet veya ritim bozukluğu gibi kronik rahatsızlıklar için tedavi gördüğünü kanıtlar. Bu altta yatan hastalıkların zaten kalp krizini tetikleyen unsurlar olması, sonucun tıbbi mantıkla %100 örtüştüğünü gösterir.

Bölüm E — Makine Öğrenmesi Sınıflandırma Modelleri

Bu bölümün temel amacı, bireylerin klinik ve demografik verilerini (Bölüm A ve B) kullanarak, henüz tanı konmamış kişilerin kalp hastası olup olmadığını (Heart patient) öngörebilen algoritmik bir Karar Destek Sistemi (KDS) geliştirmektir. Proje yönergeleri doğrultusunda veriler modele hazırlanmış ve üç farklı sınıflandırma algoritması eğitilmiştir.

1. Veri Setinin Algoritmalara Hazırlanması (Data Preparation)

Makine öğrenmesi algoritmaları sadece matematiksel matrisleri işleyebildiği için model eğitiminden önce aşağıdaki veri mühendisliği adımları uygulanmıştır:

- **Kategorik Değişkenlerin Sayısallaştırılması (Encoding):** Veri setinde yer alan 18 adet kategorik değişken (Cinsiyet, Tansiyon, Stres vb.), LabelEncoder yöntemi kullanılarak algoritmanın anlayabileceği sayısal değerlere (0, 1, 2...) dönüştürülmüştür.
- **Veri Setinin Eğitim ve Test Olarak Ayrılması (Train/Test Split):** Modelin daha önce hiç görmediği veriler üzerindeki başarısını ölçmek adına veri seti, kılavuzda önerildiği gibi **%80 Eğitim (Train)** ve **%20 Test** olacak şekilde ikiye bölünmüştür.
- **Örneklem Çıktısı:** Eğitim setinde **261 örnek**, test setinde ise **66 örnek** kullanılmıştır.
- **Hedef değişkendeki dengesizliği (hasta azınlığı) korumak için bölme işlemi stratify=y parametresi ile tabakalı olarak yapılmıştır.**
- **Standardizasyon (Scaling):** Özellikle uzaklık ve gradyan hesaplayan Lojistik Regresyon algoritmasının büyük sayılardan (Örn: 103 kg ağırlık) olumsuz etkilenmemesi için bağımsız değişkenlere StandardScaler uygulanarak tüm veriler aynı ölçeğe çekilmiştir.


2. Modellerin Eğitimi ve Performans Karşılaştırması

Sınıflandırma problemi için tıp ve veri bilimi literatüründe en sık kullanılan üç farklı algoritma seçilmiştir: **Lojistik Regresyon**, **Karar Ağacı (Decision Tree)** ve **Random Forest (Rastgele Orman)**.

Test seti (66 hasta) üzerinden elde edilen model başarı skorları aşağıdaki matriste özetlenmiştir:

Değerlendirme Metriği	Lojistik Regresyon	Karar Ağacı (Decision Tree)	Random Forest	Metrik Açıklaması ve KDS Önemi
Accuracy (Doğruluk)	%75.76	%72.73	%72.73	Toplam doğru tahmin oranı. Veri dengesiz olduğu için tek başına yanıltıcıdır.
Precision (Kesinlik)	%87.50	%61.11	%70.00	Model "Hasta" dediğinde bunun ne kadarının gerçekten hasta olduğunu gösterir.
Recall (Duyarlılık)	%31.82	%50.00	%31.82	Gerçek hastaların yüzde kaçını kaçırmadan bulabildiğimizi gösterir (En kritik tıbbi metrik).
F1-Score	%46.67	%55.00	%43.75	Kesinlik ve Duyarlılığın harmonik ortalamasıdır. Modelin istikrarını kanıtlar.
ROC - AUC	%78.20	%71.49	%82.23	Sınıfları birbirinden ayırma gücü. İdeal 1.0'a ne kadar yakınsa o kadar başarılıdır.


Confusion Matrix - Model Karşılaştırması



Kapsamlı Metrik Analizi:

Sonuçlar incelendiğinde Lojistik Regresyon %75.7 ile en yüksek "Accuracy" (Doğruluk) oranını yakalamış gibi görünse de, "Recall" (Gerçek hastaları bulma) oranının sadece %31.82'de kaldığı görülmektedir. Bu durum modelin, hastaların büyük bir kısmına (yaklaşık %68'ine) yanlışlıkla "Sağlıklı" (False Negative) teşhisi koyduğunu gösterir. Karar Ağacı modeli ise %50.0 Recall skoru ve %55.0 F1 skoru ile hastaları tespit etmede (Recall bazında) en agresif ve başarılı algoritma olmuştur.


3. Confusion Matrix (Karmaşıklık Matrisi) İncelemesi



Karmaşıklık matrisleri, modellerin yaptığı "ölümcül hataları" görselleştirir:

- Tüm modeller sol üst hücrede (True Negative - Sağlıklıya sağlıklı deme) çok başarılı olmuştur çünkü veri setinin %67'si zaten sağlıklıdır.
- Ancak sağ alt hücreye (True Positive - Hastaya hasta deme) bakıldığında modeller zorlanmıştır. Gerçek hayatta hastanelerde kullanılacak bir sistemde **yanlış pozitif** (sağlıklıya hasta demek) bir tolere edilebilir risk iken, **yanlış negatif** (hastaya sağlıklı demek) tolere edilemez bir hatadır. Modellerin Recall değerlerinin düşüklüğü, veri setindeki hasta veri sayısının yetersizliğinden (108 kişi) kaynaklanmaktadır.

ROC Eğrisi — Model Karşılaştırması




ROC Eğrisi ve AUC (Area Under Curve) Analizi

ROC Eğrisi (Receiver Operating Characteristic) incelenmiştir.

- Eğrinin altında kalan alan (AUC) hesaplandığında; Random Forest (Rastgele Orman) algoritması 0.8223 (%82.2) AUC skoru ile sınıfları birbirinden ayırma (discriminative power) konusunda birinciliği elde etmiştir.
- Rastgele tahmini simgeleyen %50'lik kesikli çizginin çok üzerinde yer alan bu eğriler (0.78, 0.71, 0.82), seçtiğimiz bağımsız değişkenlerin (Tansiyon, Yaş, BMI) kalp hastalığını tahmin etmek için son derece doğru seçilmiş (Feature Engineering) nitelikler olduğunu matematiksel olarak kanıtlamaktadır.

Random Forest — Değişken Önemi (Feature Importance)



- Amacı:** Geliştirilen en başarılı model olan Random Forest algoritmasının, kalp hastalığı riskini tahmin ederken hangi değişkenlerden (features) en çok "Bilgi Kazancı" (Information Gain) sağladığını matematiksel olarak sıralamak
- Veri Bilimi Çıkarımı:** Grafik incelendiğinde, modelin karar mekanizmasını yönlendiren en güçlü 5 faktörün sırasıyla **BMI (0.1123)**, **Boy (0.0963)**, **Kilo (0.0939)**, **Kan Basıncı (0.0914)** ve **Yaş (0.0747)** olduğu görülmektedir.
- Algoritmik Davranış Analizi:** BMI, Boy ve Kilo gibi sürekli (sayısal) değişkenlerin en üst sıraları domine etmesi, karar ağacı algoritmalarının doğasıyla mükemmel bir uyum içindedir. Sayısal değişkenler algoritma için daha fazla bölünme (split) noktası sunduğundan, modeli eğitirken kategorik değişkenlere kıyasla daha yüksek bir "Gini Importance" skoru üretirler. EDA (Görselleştirme) aşamasında tespit ettiğimiz "Obezite (BMI) ve Hipertansiyonun" hastalığı tetiklediği hipotezi, model tarafından istatistiksel olarak doğrulanmıştır.
- Beklenmeyen İlgörüler (Insight):** Tıbbi olarak çok kritik görünen *Diabetes (Diyabet - 0.0365)* ve *Family History (Aile Öyküsü - 0.0304)* gibi genetik faktörlerin listenin en altında yer alması dikkat çekicidir. Bu durum veri setindeki katılımcıların mevcut fiziksel durumlarının (kilo, tansiyon, yaş) ve yaşam tarzlarının, geçmiş tıbbi öykülerinden çok daha belirleyici bir risk faktörü olduğunu kanıtlamaktadır. Ayrıca "Marital status" (Medeni Durum - 0.0678) değişkeninin ortalarda yer alması, yaş faktörü ile arasındaki sosyolojik korelasyonun modele yansıdığını göstermektedir.

Bölüm F — Model Yorumlama ve Performans Değerlendirmesi

Bölüm E'de eğitilen Lojistik Regresyon, Karar Ağacı ve Random Forest modellerinin çıktıları, sadece matematiksel skorlar üzerinden değil; gerçek hayattaki tıbbi kullanılabilirlik, hata maliyetleri ve karar destek sistemleri (KDS) perspektifiyle aşağıdaki başlıklarda yorumlanmıştır.

11. Hangi model daha başarılı oldu?

Modellerin başarısı tek bir metriğe indirgenemese de, sınıfları birbirinden ayırma gücünü ölçen **ROC-AUC (Eğri Altında Kalan Alan)** metriği baz alındığında **Random Forest (Rastgele Orman)** algoritması en başarılı model olmuştur.

- Random Forest, **0.8223 (%82.2)** AUC skoru ile Lojistik Regresyon (0.7820) ve Karar Ağacı'nı (0.7149) geride bırakmıştır.
- Ağaç tabanlı topluluk (ensemble) öğrenme mantığıyla çalışan Random Forest, aşırı öğrenmeyi (overfitting) engelleyerek dengesiz veri setindeki non-lineer (doğrusal olmayan) örüntüleri yakalamada en stabil ve güvenilir (robust) performansı sergilemiştir.

12. Accuracy (Doğruluk) tek başına yeterli bir metrik midir?

Kesinlikle hayır. Kalp hastalığı tahmini gibi "**Sınıf Dengesizliği**" (**Class Imbalance**) barındıran veri setlerinde Accuracy (Doğruluk) en yanıltıcı (tuzak) metriktir.

- Veri setimizdeki bireylerin yaklaşık %67'si zaten sağlıklıdır ("No" sınıfı). Eğittiğimiz model hiçbir matematiksel hesaplama yapmadan, önüne gelen her hastaya körü körüne "Sen Sağlıklıydın" dese bile %67 oranında bir Doğruluk (Accuracy) oranına ulaşacaktır.
- Lojistik Regresyon modelimiz %75.76 Accuracy vermiş gibi görünse de, azınlık sınıfı olan gerçek hastaları bulmada yetersiz kalmıştır. Bu nedenle Accuracy tek başına modelin zekasını değil, sadece çoğunluğu ezberleme kapasitesini yansıtabilir.

13. Recall (Duyarlılık / Hassasiyet) değeri neden önemlidir?

Recall metriği, makine öğrenmesi modellerinin tıbbi teşhislerdeki "hayat kurtarıcı" filtresidir. Recall, "Gerçekte kalp hastası olan kişilerin yüzde kaçını modelimiz doğru tahmin edebildi?" sorusunun cevabıdır.

- **Hata Maliyeti Asimetrisi:** Tıbbi bir karar destek sisteminde iki tür hata vardır. Sağlıklı birine "hastasın" demek (False Positive) sadece gereksiz efor (ekstra kan testi, EKG) maliyeti yaratır. Ancak gerçek bir kalp hastasına "sen sağlıklıydın, gidebilirsin" demek (False Negative) ölümcül bir hatadır.
- Recall değeri, modelin hastaları "gözden kaçırma" (False Negative) ihtimaliyle ters orantılıdır. Modelin güvenilir olup hastayı eve göndermemesi için Recall değerinin maksimize edilmesi şarttır.

14. Model kalp hastası olan bireyleri başarılı şekilde yakalayabiliyor mu?

Maalesef, mevcut haliyle model gerçek hastaları yakalama konusunda yetersiz (başarısız) kalmaktadır.

- Modellerimizin Sınıflandırma Raporları incelendiğinde; "Evet" (Kalp Hastası) sınıfı için Recall değerleri Lojistik Regresyon ve Random Forest'ta **%31.82**, Karar Ağacı'nda ise ancak **%50.00** seviyesinde kalmıştır.
- Bu sonuç, en iyi senaryoda bile modelin gerçekte hasta olan her 2 kişiden 1'ini gözden kaçırdığı (False Negative teşhis koyduğu) anlamına gelmektedir. Model sağlıklıları mükemmel yakalarken, hedef kitle olan hastaları yakalamakta sınıf dengesizliğinin kurbanı olmuştur.

15. Modelde en önemli değişkenler hangileri olabilir?

Random Forest algoritması üzerinden çıkarılan "Değişken Önemi" (Feature Importance) grafiği incelendiğinde, modelin karar almasını sağlayan en önemli 5 kök değişken sırasıyla şunlardır:

1. BMI (Vücut Kitle İndeksi)

2. Height (Boy Uzunluğu)

3. Weight (Kilo)

4. Blood Pressure (Kan Basıncı)

5. Age (Yaş)

- **Yorum:** Model, hastanın genetik mirasına (Aile Öyküsü) veya kronik diyabet durumuna bakmaktan ziyade, o anki fiziksel gerçekliğine (kilosuna, yaşına ve tansiyonuna) bakarak çok daha net bir hastalık tahmini yapabildiğini kanıtlamıştır.

16. Modelin gerçek hayatta kullanılmasının sınırlılıkları nelerdir?

Geliştirilen bu makine öğrenmesi modelinin canlıya (production) alınarak hastanelerde doğrudan klinik karar vermek için kullanılmasını engelleyen 4 temel sınırlılık bulunmaktadır:

1. **Veri Hacminin Yetersizliği:** 327 kişilik (Eğitim seti: 261, Test: 66) bir veri tabanı, derin öğrenme ve kompleks algoritmaların genelleme yapabilmesi için son derece küçüktür (Underfitting riski).
2. **Recall Düşüklüğü:** Hastaların %50'den fazlasını kaçırarak bir sisteme hiçbir hekim güvenemez. Modelin "False Negative" oranı klinik toleransın çok üzerindedir.
3. **Eksik Klinik Parametreler:** Gerçek bir kardiyoloji KDS'sinde olması gereken LDL/HDL kolesterol laboratuvar değerleri, anlık EKG sinyalleri ve Troponin enzimi gibi majör tıbbi veriler veri setinde yoktur.
4. **"Self-Reported" (Beyana Dayalı) Veri Sorunu:** Veri setindeki depresyon, uyku kalitesi ve stres düzeyi gibi metrikler sensör veya doktor ölçümü değil, hastanın kendi subjektif beyanıdır. Bu durum veriye "yanlılık" (bias) katmaktadır. Model bu haliyle doktorların yerini alamaz, sadece onlara ikinci bir görüş sunan erken uyarı asistanı olabilir.

Bölüm G — Sonuç ve Yorum

Büyük Veri Analizi projesi kapsamında Heart_Dataset_Cleaned.csv veri seti üzerinde gerçekleştirilen Keşifsel Veri Analizi (EDA) ve Makine Öğrenmesi (Lojistik Regresyon, Karar Ağacı, Random Forest) süreçlerinden elde edilen nihai bulgular, proje yönergesindeki kritik sorular çerçevesinde aşağıda özetlenmiştir.

17. Veri setinde kalp hastalığı ile en çok ilişkili görünen faktörler nelerdir?

Gerçekleştirilen istatistiksel testler ve özellikle Random Forest modelinin "Değişken Önemi" (Feature Importance) analizine göre, kalp hastalığını tetikleyen ve modeli en çok yönlendiren faktörler sırasıyla şunlardır:

1. **Fiziksel / Antropometrik Ölçümler:** Vücut Kitle İndeksi (BMI), Kilo ve Boy. (Obezitenin kardiyovasküler sistem üzerindeki baskısı).
2. **Klinik Değerler:** Kan Basıncı (Blood Pressure). Hipertansiyon, kalp hastalıklarının bir numaralı klinik tetikleyicisidir.
3. **Demografik Faktörler:** Yaş (Age). Yaşın ilerlemesiyle riskin logaritmik olarak artması. Ek olarak, sadece tıbbi değil; "Fiziksel Aktivite Sıklığı" ve "Stres Düzeyi" gibi yaşam tarzı faktörlerinin de hastalıkla çok güçlü bir istatistiksel korelasyona sahip olduğu kanıtlanmıştır.

18. Yaş, BMI, diyabet, hipertansiyon, sigara ve fiziksel aktivite gibi faktörler beklenen yönde sonuç verdi mi?

Evet, bu faktörlerin tamamı tıp literatürü ve genel sağlık bilgisiyle %100 uyumlu, beklenen yönde sonuçlar vermiştir:

- **Yaş ve BMI:** Doğrusal artış (Pozitif Korelasyon). Yaş ilerledikçe ve BMI obezite sınırına (30+) yaklaştıkça hastalık oranı dramatik şekilde artmıştır.
- **Hipertansiyon ve Diyabet:** Her iki kronik rahatsızlık da kalp krizi için "komorbidite" (eşlik eden/tetikleyen hastalık) olarak çalışmış, bu kategorilerdeki bireylerin kalp hastası olma oranı sağlıklı gruba göre katlanarak yükselmiştir.
- **Sigara:** Düzenli tütün kullanımı (Regularly), damar sağlığını bozarak risk oranını artırmıştır.
- **Fiziksel Aktivite:** Koruyucu etki (Negatif Korelasyon). Sedanter (hareketsiz) yaşam tarzı sürenlerde risk zirve yaparken, haftada 5 gün ve üzeri spor yapan grupta hastalık riski istatistiksel olarak sıfıra yaklaşmıştır.

19. Veri setinin güçlü yönleri nelerdir?

Bir veri madenciliği projesi olarak değerlendirildiğinde veri setinin üç temel güçlü yönü bulunmaktadır:

1. **Bütüncül (Holistik) Yaklaşım:** Sadece hastane testlerine (tansiyon, diyabet) değil; kişinin uykusu, stresi, beslenmesi ve hareketliliği gibi sosyolojik ve psikolojik "yaşam tarzı" verilerine de sahip olması, hastalıkların kök neden analizinin (Root Cause Analysis) yapılabilmesini sağlamıştır.
2. **Temiz Veri Mimarisi:** Veri setinin halihazırda ön işlemden geçmiş (Cleaned) olması; eksik veri (NaN/Null) veya mükerrer (Duplicate) kayıt barındırmaması, makine öğrenmesi modellerinin hatasız çalışmasını sağlamıştır.
3. **Veri Tiplerinin Çeşitliliği:** Sayısal ve kategorik verilerin dengeli birleşimi, farklı kodlama (encoding) stratejilerinin ve algoritmaların test edilmesine olanak tanımıştır.

20. Veri setinin sınırlılıkları nelerdir?

Gerçek hayattaki uygulanabilirliği kısıtlayan temel zafiyetler şunlardır:

1. **Veri Hacminin Küçüklüğü:** Toplam 327 satırlık bir veri seti, makine öğrenmesi modellerinin derinlemesine genelleme yapabilmesi için yetersizdir (Underfitting riski).
2. **Sınıf Dengesizliği (Class Imbalance):** Hastaların (%33) sağlıklı bireylere (%67) kıyasla çok azınlıkta olması, modellerin gerçek hastaları bulma (Recall) performansını ciddi şekilde düşürmüştür.
3. **Beyana Dayalı (Self-Reported) Veriler:** Bireylerin kilolarını, uyku kalitelerini veya sigara içme sıklıklarını anketörlere olduğundan farklı (daha iyi) yansıtmaya ihtimali, verinin objektifliğini zedeleyen önemli bir istatistiksel yanlılık (Bias) yaratmaktadır.

21. Daha iyi bir analiz için hangi ek verilere ihtiyaç olurdu?

Makine öğrenmesi modelinin klinik bir kesinliğe ulaşabilmesi için, beyana dayalı anket verilerinin ötesinde doğrudan ölçülebilir tıbbi parametrelere ihtiyaç vardır:

- **Kan Laboratuvar Sonuçları:** Sadece "Diyabet" etiketi yerine "Açlık Kan Şekeri (mg/dL)" ve "HbA1c" oranları; ayrıca LDL (Kötü) ve HDL (İyi) Kolesterol, Trigliserit seviyeleri.
- **Kardiyoloji Testleri:** EKG (Elektrokardiyografi) ritim sinyalleri, kalp ritmi anormallikleri, Efor testi sonuçları ve Troponin enzim değerleri.
- **Detaylandırılmış Veriler:** Sadece "İlaç kullanıyor" yerine kullanılan spesifik ilacın adı (Örn: Beta bloker, Kan sulandırıcı) ve hastanın milimetrik yaş değeri (Örn: "<35" kategorisi yerine "24 yaşında" şeklinde kesin sürekli veriler).

22. Bu veri seti ile gerçek hayatta klinik karar verilebilir mi? Neden?

Hayır, bu veri seti ve kurulan modeller ile gerçek hayatta doğrudan klinik bir karar verilemez.

- **Tıbbi Etik ve Hata Maliyeti:** Kurulan algoritmaların (Örneğin Random Forest) hastalığı tespit etme (Recall) oranı %35-50 bandında kalmıştır. Bu durum, sisteme giren gerçek kalp hastalarının en az yarısına "Sen Sağlıklıydın" (False Negative) teşhisi konulacağı anlamına gelir. Tıbbi bilişim sistemlerinde bir hastanın gözden kaçırılması ölümcül bir hata maliyetidir.
- **KDS Olarak Kullanım Vizyonu:** Bu sistem hiçbir zaman bir hekimin yerini alarak teşhis (diagnostics) koyamaz. Ancak veri seti büyütülür ve sistem optimize edilirse; hastanelerde bir "Erken Uyarı ve Triyaj Sistemi" veya sigorta şirketleri için bir "Risk Skorum (Karar Destek Aracı)" olarak hekimlere "ikinci bir algoritmik görüş" sunmak amacıyla başarıyla kullanılabilir.

SINIRLILIKLAR:

Her veri madenciliği ve Karar Destek Sistemi (KDS) projesi, dayandığı verinin kalitesi ve analitik çerçevenin kapsamı ile sınırlıdır. Bu projede elde edilen %82'lik ROC-AUC başarısına ve çıkarılan anlamlı istatistiksel örüntülere rağmen, modelin gerçek hayat (production) senaryolarında doğrudan tıbbi bir teşhis aracı olarak kullanılmasını engelleyen yapısal ve algoritmik sınırlılıklar aşağıda maddeler halinde raporlanmıştır:

1. Örneklem Hacminin Yetersizliği (Sample Size Constraint) Proje kapsamında analiz edilen Heart_Dataset_Cleaned.csv veri seti, yalnızca 327 katılımcıdan oluşmaktadır. Makine öğrenmesi algoritmalarının (özellikle Random Forest gibi topluluk/ensemble modellerin) toplumun genelini temsil edebilen (genellenebilir) ve varyansı düşük kurallar öğrenebilmesi için bu veri hacmi oldukça yetersizdir. Eğitim (Train) setinde sadece 261 örneğin bulunması, modelde "Eksik Öğrenme" (Underfitting) veya lokal ezberleme riskini barındırmaktadır.

2. Hedef Değişkenindeki Sınıf Dengesizliği (Class Imbalance) Projenin en büyük istatistiksel zafiyeti, hedef değişken olan Heart_patient içindeki dağılım eşitsizliğidir. Katılımcıların yaklaşık %67'si "Sağlıklı" (No), yalnızca %33'ü "Hasta" (Yes) sınıfındadır. Bu durum, algoritmaların çoğunluk sınıfına karşı "Algoritmik Yanlılık" (Algorithmic Bias) geliştirmesine neden olmuştur. Modelin Accuracy (Doğruluk) oranları yüksek görünse de, asıl önemli olan azınlıktaki hastaları yakalama performansı (Recall / Duyarlılık) %31 ile %50 bandında kısıtlı

kalmıştır. (Not: İleriki çalışmalarda bu sorunu aşmak için SMOTE gibi sentetik veri çoğaltma teknikleri uygulanmalıdır).

3. "Sosyal Arzu Edilebilirlik" Yanlılığı ve Beyana Dayalı Veriler (Self-Reported Bias) Veri setinde yer alan Fiziksel Aktivite, Beslenme Alışkanlıkları (Food habits), Sigara/Alkol Tüketimi ve Stres Seviyesi gibi kritik değişkenler, sensörler veya klinik gözlemlerle değil, tamamen bireylerin kendi beyanlarıyla oluşturulmuştur. Anket metodolojilerinde bilinen "Sosyal Arzu Edilebilirlik Yanlılığı" gereği, bireylerin toksik alışkanlıklarını azımsama veya spor/uyku kalitelerini abartma eğiliminde olmaları, verinin nesnelliğini (objectivity) ve dolayısıyla modelin güvenilirliğini zedeleyen temel bir sınırlılıktır.

4. Klinik Sürekli (Continuous) Değişkenlerin Eksikliği Modern bir hastane bilgi sisteminde (HBS) tansiyon "Normal" veya "Hipertansiyon" şeklinde sadece metinsel (kategorik) olarak tutulmaz; "135/85 mmHg" gibi hassas sürekli sayılar olarak tutulur. Benzer şekilde, Diyabet için "HbA1c yüzdesi", Kolesterol için "LDL/HDL seviyeleri" gibi sayısal tıbbi parametrelerin veri setinde bulunmaması, algoritmaların "Bilgi Kazancı" (Information Gain) katsayısını kısıtlamıştır. Karar ağaçları hassas matematiksel sınırları (threshold) öğrenmek yerine geniş kategorilere sıkışmıştır.

5. Nedensellik (Causality) ve Korelasyon İkilemi Bu proje kapsamında uygulanan Keşifsel Veri Analizi (EDA) ve sınıflandırma modelleri, değişkenler arasındaki matematiksel "Korelasyonu" (birlikte değişimi) kusursuz bir şekilde yakalamıştır. Ancak istatistiğin altın kuralı olan "*Korelasyon, nedensellik demek değildir*" ilkesi gereği; stresin veya uykusuzluğun doğrudan kalp hastalığına **neden olduğunu** kesin olarak kanıtlamaz, sadece bu faktörlerin hastalarla güçlü bir **ilişkisi olduğunu** gösterir.

6. Sosyodemografik ve Çevresel Veri Eksikliği Kalp hastalıkları sadece biyolojik değil, sosyolojik etmenlere de bağlıdır. Veri setinde hastaların gelir düzeyi, eğitim durumu, coğrafi konumu ve çalışma ortamındaki fiziksel/kimyasal riskler gibi çevresel değişkenler bulunmamaktadır. Bu durum, modelin risk analizini sadece biyolojik eksende dar bir çerçeveye hapsetmiştir.

Genel Sonuç ve Değerlendirme (Executive Conclusion)

Bu proje kapsamında yürütülen veri madenciliği ve Büyük Veri analitiği çalışmaları, kardiyovasküler hastalıkların sadece anlık bir klinik bulgu olmadığını; yaş, genetik miras, antropometrik ölçümler (BMI) ve yaşam tarzı alışkanlıklarının (hareketsizlik, stres, sigara) yıllar süren karmaşık etkileşiminin bir sonucu olduğunu istatistiksel olarak kanıtlamıştır.

Çalışmanın en önemli analitik çıktısı, geleneksel sağlık yönetimindeki "reaktif" (hastalık oluştuktan sonra müdahale eden) yaklaşımın, makine öğrenmesi algoritmalarıyla nasıl "proaktif" (önleyici) bir sisteme dönüştürülebileceğinin gösterilmesidir. Keşifsel Veri Analizi (EDA) aşamasında tespit edilen yüksek tansiyon, obezite ve hareketsizlik gibi majör risk faktörleri, modelleme aşamasında algoritmalar tarafından başarıyla öğrenilmiştir. Özellikle topluluk öğrenmesi (ensemble learning) mantığıyla çalışan **Random Forest algoritması**, %82.2'lik ROC-AUC skoru ile verideki doğrusal olmayan (non-linear) hastalık örüntülerini yakalamada en yüksek performansı sergilemiştir.

Bir Yönetim Bilişim Sistemleri (YBS) projesi perspektifiyle değerlendirildiğinde; geliştirilen bu altyapı salt bir istatistik ödevi değil, hastane bilgi sistemlerine (HBS) entegre edilebilecek bir **Klinik Karar Destek Sisteminin (KDS)** prototipidir. Her ne kadar veri setinin hacimsel küçüklüğü ve sınıf dengesizliği modelin doğrudan klinik bir teşhis aracı olarak kullanılmasını (özellikle Recall

zafiyeti nedeniyle) şu aşamada kısıtla da; bu sistem hastanelerdeki triyaj süreçlerini hızlandırmak, sigorta şirketleri için risk skorlaması yapmak ve hekimlere "ikinci bir algoritmik görüş" sunmak adına muazzam bir potansiyel taşımaktadır.

Sonuç olarak bu proje; ham ve dağınık sağlık verilerinin, doğru veri mühendisliği ve makine öğrenmesi metodolojileriyle işlendiğinde insan hayatını kurtarabilecek, stratejik ve katma değerli bir "İş Zekası" (Business Intelligence) ürününe dönüştüğünü başarıyla ortaya koymuştur.

Kaynakça:

A. Veri Bilimi ve Makine Öğrenmesi Literatürü

1. Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann. (Veri ön işleme, eksik veri analizi ve sınıflandırma algoritmalarının teorik altyapısı için).
2. Provost, F., & Fawcett, T. (2013). *Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking*. O'Reilly Media. (Model performansı değerlendirme, ROC-AUC ve Confusion Matrix analizlerinin işletme/KDS perspektifinden yorumlanması).
3. Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32. (Random Forest algoritmasının "Feature Importance" - değişken önemi ve ensemble/topluluk öğrenmesi teorisi).
4. Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321-357. (Sınıf dengesizliği / Class Imbalance probleminin teşhisi ve Recall zafiyetinin literatürdeki yeri).

B. Tıp ve Kardiyovasküler Sağlık Literatürü

5. World Health Organization (WHO). (2021). *Cardiovascular diseases (CVDs) Fact sheet*. (Kardiyovasküler risk faktörleri; yaş, obezite, tütün kullanımı ve fiziksel inaktivite ilişkileri).
6. American Heart Association (AHA). (2023). *Understanding Blood Pressure Readings*. (Hipertansiyon ve Pre-hipertansiyon kategorilerinin kalp krizi riskiyle olan klinik ilişkisi).
7. Kannel, W. B., McGee, D. L. (1979). Diabetes and Cardiovascular Disease: The Framingham Study. *JAMA*, 241(19), 2035-2038. (Diyabetin ve gizli şekerin kardiyovasküler hastalıklar üzerindeki komorbidite etkisi).
8. Dimsdale, J. E. (2008). Psychological Stress and Cardiovascular Disease. *Journal of the American College of Cardiology*, 51(13), 1237-1246. (Stres düzeyinin kalp sağlığı ve otonom sinir sistemi üzerindeki psikosomatik etkileri).

C. Kullanılan Yazılım ve Analiz Araçları

9. McKinney, W. (2010). Data Structures for Statistical Computing in Python. In *Proceedings of the 9th Python in Science Conference* (pp. 51-56). (Keşifsel veri analizi ve veri setinin Pandas kütüphanesi ile yapısal incelemesi).
10. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830. (Lojistik Regresyon, Karar Ağacı, Random Forest modellerinin inşası ve metrik hesaplamaları).
11. Waskom, M. L. (2021). seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. (Korelasyon matrisleri, dağılım grafikleri ve makine öğrenmesi veri görselleştirmeleri).